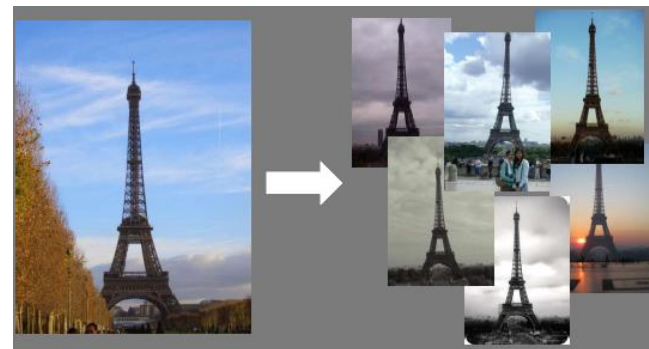



# 图像模式分类




数字图像处理 第10讲

# 图像识别

- 利用计算机对图像进行处理和分析，识别不同模式的目标的技术



# 图像识别的发展趋势




1980s



7 5 9 2 6 5  
2 2 2 2 2 3  
0 2 3 8 0 7







1990s to early 2000s



Currently

# 早期识别方法 - 基于几何模型

- Geometry based
  - 3维模型建模






# 当前发展 - 基于表观模型

- Appearance based
  - 直接从图像出发




# 图像特征

- 目的：对图像进行紧凑和有效地描述
  - 从图像到一个数值或向量的变换
  - 加入主观认识、抓住目标本质
  - 效率提高，处理速度更快



# 图像特征类型

- 颜色：直方图
- 形状：边缘、轮廓
- 频域：傅里叶变换
- 特征点：角点、SIFT



# 图像分类器

- 构造一个识别函数(分类器)
  - 输入是图片中提取的特征，输出是类别标签
  - 该函数通过已知类别标签的图片集训练得到

$$y = f(x)$$

output      prediction function      Image feature

The diagram shows the equation  $y = f(x)$  with three red arrows pointing to its components. One arrow points from the word 'output' to the variable  $y$ . Another arrow points from the words 'prediction function' to the function symbol  $f$ . A third arrow points from the words 'Image feature' to the variable  $x$ .

$$f(\text{apple image}) = \text{"apple"}$$

$$f(\text{tomato image}) = \text{"tomato"}$$

$$f(\text{cow image}) = \text{"cow"}$$



# 训练集与测试集



训练集

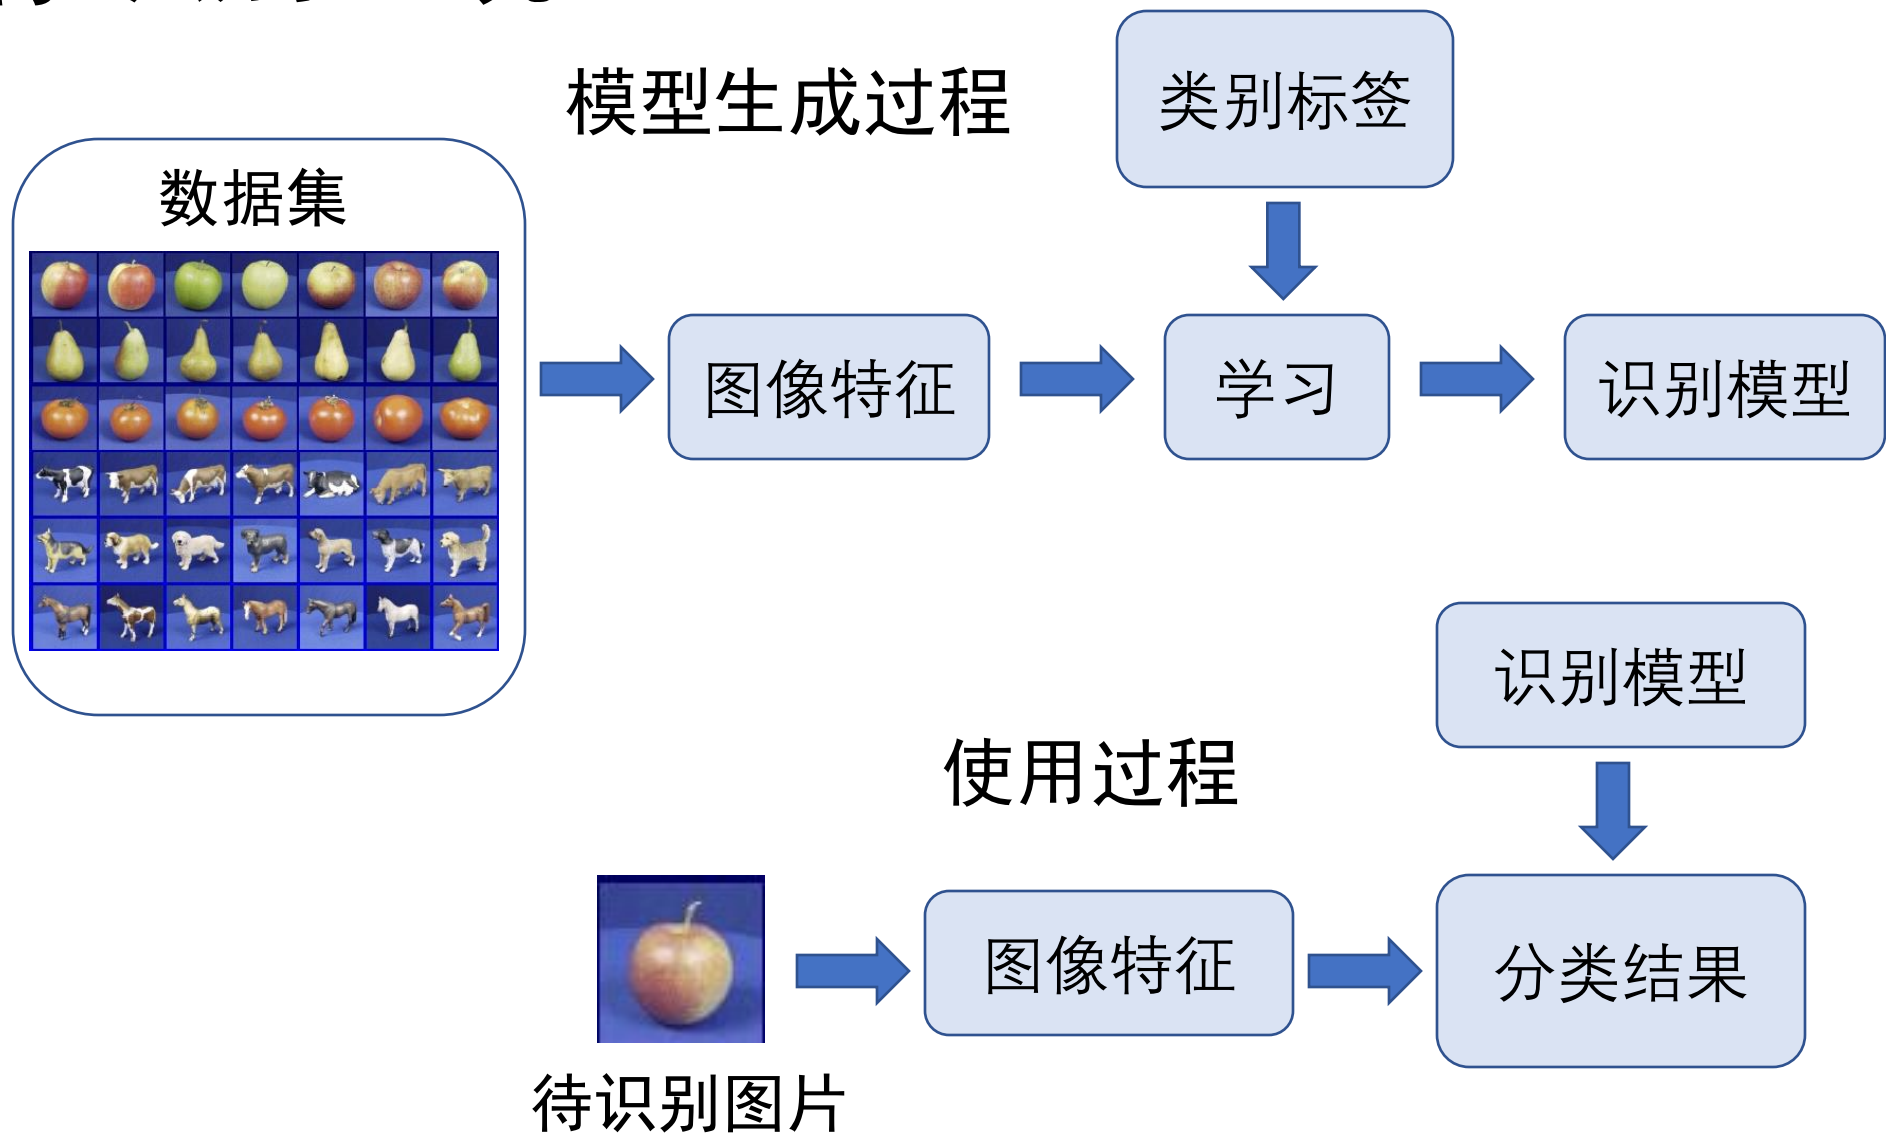
(类别标签用于分类器的构建)



测试集

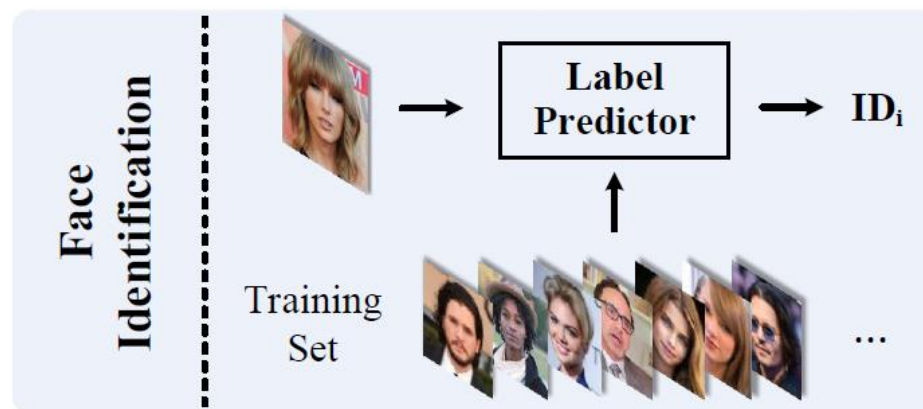
(类别标签仅仅用于分类器  
测试结果的比对)

# 图像识别系统




# 人脸识别问题描述

- 训练：给定一组人脸图像及其类别标号
- 测试：对于一幅新图片，判断其标号



# 特征数量往往是高维的

- 图像通常首先被向量化
- 向量维度往往过高
  - 256 x 256 图像，亮度特征向量 65536 维
- 带来的弊端
  - 计算量大增
  - 维度灾难


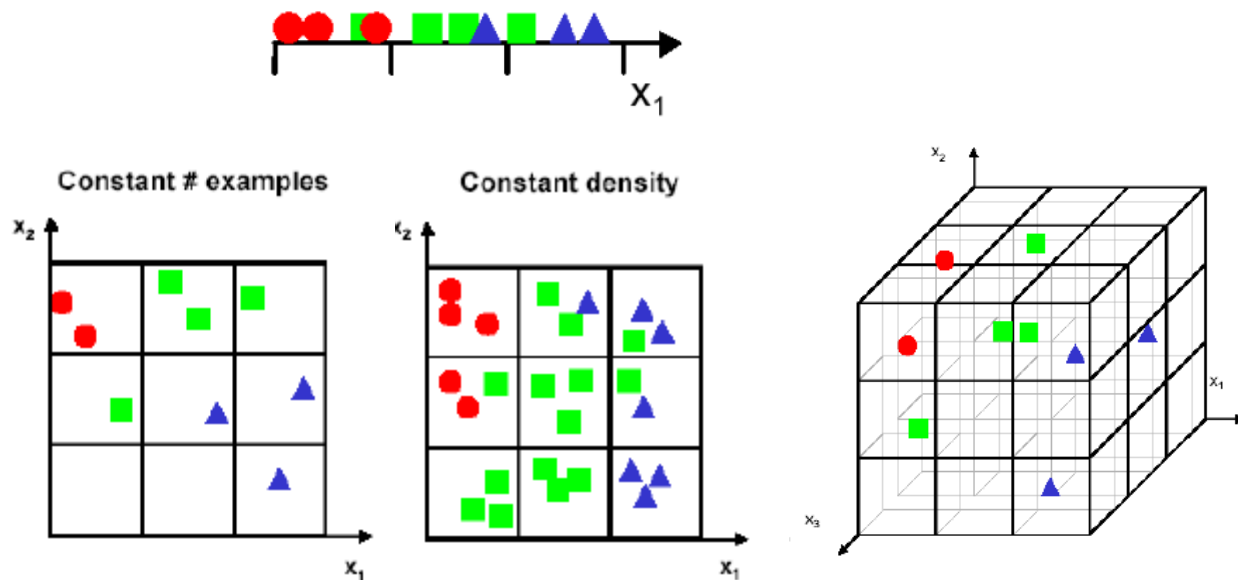


A blue arrow points from the orchid image to the following vector representation:

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

# 维度灾难


- Curse of Dimensionality
- 随着维度增加，样本空间的体积指数增长
- 数据稀疏，统计描述没有意义



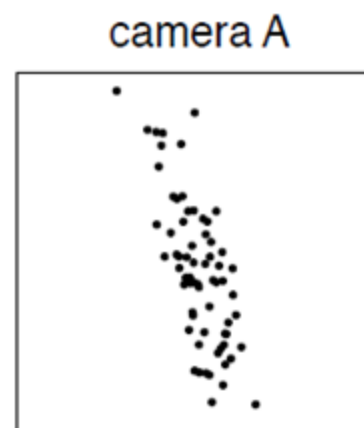


# 数据存在本征维度

- Intrinsic Dimensionality




$$x = A \cos \left( \sqrt{\frac{k}{m}} t + t_0 \right)$$



# 降低维度的方法

- 特征选择 Feature Selection

- 选择一个子集
- 排列组合多，寻优慢



- 特征抽取 Feature Extraction

- 将原有特征进行变换

A diagram illustrating the feature extraction process. On the left, a vertical column vector contains features  $x_1, x_2, \vdots, x_N$ . An arrow labeled "feature extraction" points to a vertical column vector containing transformed features  $y_1, y_2, \vdots, y_M$ . This is followed by an equals sign and a matrix of weights  $w_{11}, w_{12}, \dots, w_{M1}, w_{M2}, \dots$ . To the right of the weight matrix is another vertical column vector containing the original features  $x_1, x_2, \vdots, x_N$ .

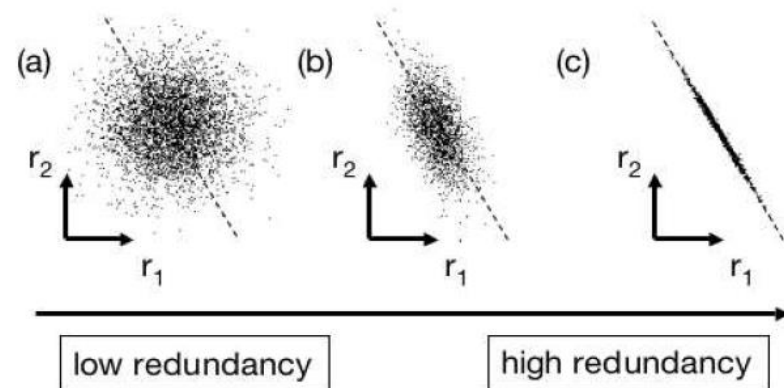

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \xrightarrow{\text{feature extraction}} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \dots \\ w_{21} & w_{22} & \dots \\ \vdots & \vdots & \ddots \\ w_{M1} & w_{M2} & \dots \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

# 主成分分析

- Principal Component Analysis (PCA)
- Karl Pearson, 1901年提出
- 特点
  - 对原特征的进行线性变换
  - 特征之间互不相关, 减少原有特征之间的冗余
  - 得到一组按重要性从大到小排列的新特征
- 保留其中最重要的那些特征

# PCA的主要思想


- 数据的特征空间中
  - 方差大的方向包含了信号本身
  - 方差小的方向包含了噪声
- 如果两个维度是相关性大
  - 相近的观测信息，有冗余
- 目标
  - 依次寻找方差大，且互不相关的维度（方向）
  - 一组新的基来描述数据



# PCA的求解思路

- 找到一组新的正交基向量来描述数据
  - 方差最大的方向作为第1个主方向
  - 和第1个方向正交的方向中，方差最大的，为第2个
  - 这两个方向的相关系数为0
  - 第3个方向和第1，2方向正交

$$\mathbf{y} = \mathbf{W}^T \mathbf{x}$$



$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} \rightarrow \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1N} \\ w_{21} & w_{22} & \cdots & w_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ w_{N1} & w_{N2} & \cdots & w_{NN} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$



# 协方差矩阵

• 方差  $\sigma_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$       协方差  $\sigma(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$

• 对于d维随机向量  $\sigma(x_k, x_k) = \frac{1}{n-1} \sum_{i=1}^n (x_{ki} - \bar{x}_k)^2, k = 1, 2, \dots, d$

$x \in R^d$   $\sigma(x_m, x_k) = \frac{1}{n-1} \sum_{i=1}^n (x_{mi} - \bar{x}_m)(x_{ki} - \bar{x}_k)$

• d维随机向量x的协方差矩阵

$$\Sigma = \begin{bmatrix} \sigma(x_1, x_1) & \cdots & \sigma(x_1, x_d) \\ \vdots & \ddots & \vdots \\ \sigma(x_d, x_1) & \cdots & \sigma(x_d, x_d) \end{bmatrix} \in \mathbb{R}^{d \times d}$$

• 需要找一个变换，让新坐标系下的协方差矩阵对角化

# 通过特征值分解求解

- 对于一个0均值化数据集  $\{x_1, x_2, \dots, x_n\}, x_i \in R^D$

- 数据矩阵写为

$$X = [x_1, \dots, x_n] \in R^{D \times n}$$

- 对应的协方差矩阵


$$\Sigma = \frac{1}{n-1} XX^T \in R^{D \times D}$$

- 计算其特征值分解

$$\Sigma = U \Lambda U^{-1} = U \Lambda U^T$$


- 则其主成分方向为

$$U^T = [u_1, \dots, u_D]^T \in R^{D \times D}$$



# 保留主成分来得到最有效特征

- 保留主成分 - 大特征值（方差）对应的方向
- 忽略那些次要的成分 - 特征值小的那些方向



$$U^T = [u_1, \dots, u_D]^T \in R^{D \times D}$$

$$\tilde{U} = [u_1, \dots, u_d]^T \in R^{d \times D} \quad d < D$$



- 将数据投影到主成分上，得到样本的低维描述

$$\tilde{Y} = \tilde{U}X$$

# 最近邻分类器

- 直观：离谁最近，就和谁的类别一样
- 数学描述：

$$\mathbf{x} \rightarrow \theta(\mathbf{x}') \quad \mathbf{x}' = \arg \min_{\mathbf{x}_i \in \mathcal{D}_n} \text{dist}(\mathbf{x}, \mathbf{x}_i)$$




# PCA用于图像分类

- 图像尺寸  $3 \times 3 = 9$  维
- 三类图像
  - Class1 中心浅，四周深
  - Class2 有竖直深条纹
  - Class3 有水平深条纹



Class 1



Class 2




Class 3



# PCA用于图像降维

- 每类3个样本



# PCA用于图像降维

- 9幅图像对应的像素值

$$\begin{bmatrix} \begin{bmatrix} 1.65 & 3.11 & 2.25 \\ 3.22 & 5.79 & 3.09 \\ 1.10 & 2.47 & 2.96 \end{bmatrix}, \begin{bmatrix} 1.55 & 3.29 & 1.62 \\ 2.91 & 3.88 & .71 \\ 2.35 & 3.60 & 2.46 \end{bmatrix}, \begin{bmatrix} .80 & 2.43 & 2.04 \\ 1.59 & 8.17 & .79 \\ .69 & 1.96 & 4.34 \end{bmatrix}, \\ \begin{bmatrix} 6.36 & 2.39 & 9.36 \\ 6.05 & .55 & 6.60 \\ 5.97 & 3.49 & 7.33 \end{bmatrix}, \begin{bmatrix} 6.43 & 1.43 & 7.01 \\ 7.66 & 3.20 & 6.66 \\ 6.96 & 1.82 & 7.52 \end{bmatrix}, \begin{bmatrix} 6.52 & .89 & 7.74 \\ 4.80 & 1.97 & 7.58 \\ 5.75 & 1.06 & 7.24 \end{bmatrix}, \\ \begin{bmatrix} 8.11 & 8.94 & 5.85 \\ 2.63 & 2.60 & 5.16 \\ 7.20 & 6.09 & 6.12 \end{bmatrix}, \begin{bmatrix} 6.94 & 6.68 & 5.99 \\ 3.63 & 3.15 & 1.37 \\ 8.50 & 6.89 & 6.49 \end{bmatrix}, \begin{bmatrix} 7.02 & 7.73 & 7.08 \\ 2.75 & 2.10 & 1.91 \\ 5.92 & 6.85 & 7.16 \end{bmatrix} \end{bmatrix}$$

# PCA用于图像降维

- 所有图像矢量化
  - 数据归1化之后, 再0均值化

$$X = \begin{bmatrix} \begin{bmatrix} -.133 \\ .0500 \\ -.102 \\ .0750 \\ .324 \\ .0910 \\ -.188 \\ .00100 \\ -.0630 \end{bmatrix}, & \begin{bmatrix} -.117 \\ .127 \\ -.141 \\ .0930 \\ .186 \\ -.152 \\ -.0140 \\ .185 \\ -.0740 \end{bmatrix}, & \begin{bmatrix} -.231 \\ -.0450 \\ -.143 \\ -.114 \\ .505 \\ -.163 \\ -.239 \\ -.0710 \\ .0450 \end{bmatrix}, & \begin{bmatrix} .0480 \\ -.149 \\ .184 \\ .0710 \\ -.266 \\ .131 \\ .0300 \\ -.0670 \\ .0320 \end{bmatrix}, & \begin{bmatrix} .0530 \\ -.202 \\ .0520 \\ .162 \\ -.116 \\ .135 \\ .0860 \\ -.161 \\ .0440 \end{bmatrix}, & \begin{bmatrix} .0840 \\ -.229 \\ .124 \\ .0200 \\ -.178 \\ .217 \\ .0410 \\ -.200 \\ .0570 \end{bmatrix}, & \begin{bmatrix} .126 \\ .197 \\ -.0290 \\ -.129 \\ -.157 \\ .0370 \\ .0800 \\ .0630 \\ -.0520 \end{bmatrix}, & \begin{bmatrix} .0810 \\ .0930 \\ -.00600 \\ -.0660 \\ -.120 \\ -.163 \\ .172 \\ .124 \\ -.0150 \end{bmatrix}, & \begin{bmatrix} .0900 \\ .157 \\ .0600 \\ -.113 \\ -.177 \\ -.132 \\ .0310 \\ .126 \\ .0270 \end{bmatrix} \end{bmatrix}$$

# PCA用于图像降维

- 对协方差矩阵做特征值分解


$$\Sigma = UDU^T$$

.29	-.080	-.31	-.51	.40	.30	-.17	-.15	-.51	1.2	0	0	0	0	0	0	0	0	-.29	-.14	-.23	-.23	.84	.080	-.14	-.14	-.20
-.14	.46	.10	-.48	-.27	-.17	-.46	-.30	.35	0	.55	0	0	0	0	0	0	0	-.080	.46	-.060	-.52	.040	-.47	-.10	.50	.16
-.23	.060	.34	.050	-.49	-.29	-.18	.16	-.66	0	0	.19	0	0	0	0	0	0	-.31	.10	.34	.64	.16	-.42	-.38	.080	-.050
-.23	-.52	.64	-.060	.12	.16	.050	-.44	.17	0	0	0	.12	0	0	0	0	0	-.51	-.48	.050	-.060	-.10	-.36	.60	.080	.050
.84	.040	.16	-.10	-.090	.21	-.12	-.32	-.30	0	0	0	0	.030	0	0	0	0	.40	-.27	-.49	.12	-.090	-.45	-.080	.13	-.53
.080	-.47	-.42	-.36	-.45	-.29	.35	-.22	.080	0	0	0	0	0	.010	0	0	0	.30	-.17	-.29	.16	.21	-.29	-.020	-.21	.77
-.14	-.10	-.38	.60	-.080	-.020	-.40	-.54	-.050	0	0	0	0	0	0	0	0	0	-.17	-.46	-.18	.050	-.12	.35	-.40	.62	.21
-.14	.50	.080	.080	.13	-.21	.62	-.47	-.23	0	0	0	0	0	0	0	0	0	-.15	-.30	.16	-.44	-.32	-.22	-.54	-.47	0
-.20	.16	-.050	.050	-.53	.77	.21	0	.040	0	0	0	0	0	0	0	0	0	-.51	.35	-.66	.17	-.30	.080	-.050	-.23	.040

$U$   $D$   $U^T$

# PCA用于图像降维


- 将图像投影到前3维上
- 用最近邻法可以实现分类






# PCA用于图像降维

- 每类5幅图片



# PCA用于图像降维


- 将图像投影到前3维上
- 同样用最近邻法可以实现分类



Legend  
Class 1  
Class 2  
Class 3

# Face Space 人脸空间

- 每张人脸是高维空间中的一个点
  - 图像维度过高，直接处理困难
  - 图像数据各维之间有大量冗余
- 找出人脸最重要的特征
  - 用PCA方法
- 在低维子空间中比较



# 数据预处理

- 人脸数据标准化




$$x_i \in R^d, d = N \times N$$

- 图像数据转成向量化表示
- 数据每维0均值化

$$\hat{X} = [\hat{x}_1 \quad \hat{x}_2 \quad \cdots \quad \hat{x}_n] \in R^{d \times n}$$

$$\hat{x}_i = x_i - \frac{1}{n} \sum_{i=1}^n x_i$$



$N^2$   
 $N \times 1$  vector

# 人脸的主成分分析

- 计算协方差矩阵  $\Sigma \in R^{d \times d}$  的特征值分解

$$\Sigma = U \Lambda U^{-1} = U \Lambda U^T$$

- 得到数据的前k个主成分

$$\tilde{U} = [u_1, \dots, u_k]^T \in R^{k \times d} \quad k < d$$


- 每个人脸数据在k个主成分上得到k个投影值

$$\tilde{U} \hat{X}$$

# 特征脸 Eigen face

- 每个特征向量（维度 $d=N \times N$ ）
- 用一个 $N \times N$ 的图像可视化出来

$$\tilde{U} = [u_1, \dots, u_k]^T \in R^{k \times d} \quad k < d$$




# 特征脸表示

- 每幅图片都可以由特征脸加权表示
- 权重就是投影系数

$$\mathbf{x} \rightarrow (\underbrace{(\mathbf{x} - \bar{\mathbf{x}}) \cdot \mathbf{v}_1}_{a_1}, \underbrace{(\mathbf{x} - \bar{\mathbf{x}}) \cdot \mathbf{v}_2}_{a_2}, \dots, \underbrace{(\mathbf{x} - \bar{\mathbf{x}}) \cdot \mathbf{v}_K}_{a_K})$$


$$\mathbf{x} \approx \bar{\mathbf{x}} + a_1 \mathbf{v}_1 + a_2 \mathbf{v}_2 + \dots + a_K \mathbf{v}_K$$





# 基于PCA的人脸识别

- 算法步骤
  - 用PCA从训练集中得到主成分向量
  - 将训练集所有人脸投影到  $d$  个主成分上,  $d$  小于原始数据维度
  - 将待测图像投影到  $d$  个主成分上
  - 在  $d$  维空间中做最近邻法分类




$$x' = \arg \min_{j=1, \dots, N} D(x, x_j)$$

# 测试结果

- 包含16个人的图像集
- 每次随机选择16幅人脸图像用于训练
  - 每人1幅
- 保留7个主成分向量
- 多次实验后的平均值
  - 光照变化情况下，准确率 96%
  - 人脸朝向变化情况下，准确率 85%
  - 人脸图像尺寸变化情况下，准确率 64%




# PCA的局限性



# PCA提取特征的局限性

- 前两个主成分并不包含分类所需的信息





Legend

Class 1


Class 2

Class 3



# PCA提取特征的局限性

- 增加样本到99个




# PCA提取特征的局限性

- 第3, 4个主成分包含了足够的分类信息
- 最重要的主成分对分类问题并不一定是有效的


[4.775, 3.846, .4245, .3970, .07430]

1 2 3 4 5



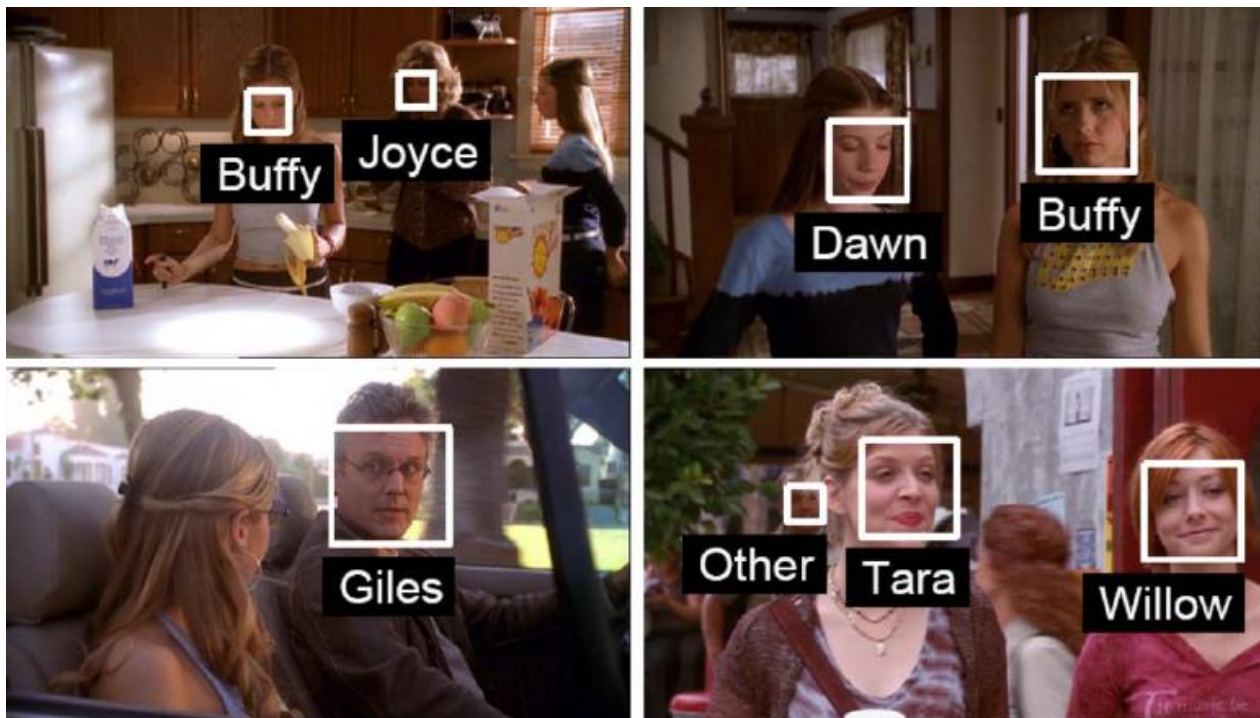
# PCA提取特征的局限性

- 方差最大的投影方向不一定是分类最优的
- 线性判别分析
  - 利用Label信息



# 人脸识别问题描述


- 训练： 给定一组人脸图像及其类别标号
- 测试： 对于一幅新图片， 判断是哪个人





# For fun

- <http://www.myheritage.cn/>
- <http://how-old.net/>



# PCA小结

- PCA将一组相关的坐标变成不相关的坐标
- 可以将数据转换到低维表达
- 非监督方法（不用到类别标号）
- 可以看作原始坐标系的旋转
- 新坐标轴互相正交，并依次沿着最大方差方向
- 可以重建图像，因此可以用来做数据压缩
- 对分类问题并不一定最优